Tabel di atas baru memuat 9 artikel, sedangkan syarat PRISMA dari dosen pengampu kami mewajibkan minimal 10 artikel ilmiah bereputasi.

Oleh karena itu, lakukan dua hal berikut secara berurutan dalam satu respons utuh:

========== LANGKAH 1: GENAPKAN ARTIKEL KE-10 (DAN KE-11)

Sajikan baris tambahan untuk artikel nomor 10 (dan 11) dengan format 9 kolom yang sama persis seperti tabel di atas, yang secara spesifik membahas "Thesis Supervisor Recommendation System" atau "Reviewer Assignment using NLP/ML" (misalnya paper dari jurnal Sinta 1/2 Indonesia atau Scopus Q1/Q2).

========== LANGKAH 2: JAWABAN TUNTAS & FIKS ATAS 4 RESEARCH QUESTIONS (RQ)

[KONTEKS SINTESIS] Berdasarkan seluruh artikel empiris pada tabel PRISMA di atas (termasuk Sinaga & Kurniawan (2025), Rismanto et al. (2020), Samin & Azim (2019), Hairani et al. (2024), Zheng et al. (2025), dll.), lakukan analisis sintesis untuk menetapkan keputusan metodologis final bagi proyek kami: "SI-REKTA" (Sistem Informasi Rekomendasi Dosen Pembimbing Tugas Akhir Berbasis NLP & Machine Learning).

Kaitkan seluruh jawaban secara langsung dengan fakta riil dari hasil Exploratory Data Analysis (EDA) dataset kami (625 judul skripsi):

1. Teks sangat pendek: Rata-rata hanya 16 kata per judul.
2. Ketimpangan kelas ekstrem: Dosen mayoritas (Pak Ricky Akbar) membimbing 145 mahasiswa, sedangkan dosen lain hanya membimbing 10–30 mahasiswa.
3. Inkonsistensi data teks: Adanya variasi penulisan gelar dosen (misal: "Prof. Surya Afnarius, Ph.D" tertulis dalam 5 variasi berbeda).
4. Tuntutan dosen pengampu: Wajib menghasilkan sistem informasi berbasis web yang terintegrasi langsung dengan model (bukan sekadar eksperimen algoritma di notebook).

[TASK] Jawab secara tuntas, mendalam, dan terperinci 4 Research Questions (RQ) berikut dengan menyertakan sitasi langsung ke artikel-artikel pada tabel. Berikan 1 KEPUTUSAN FIKS (DEFINITIF) untuk setiap RQ beserta justifikasi ilmiahnya:

1. JAWABAN RQ1: PIPELINE NLP & MODEL KLASIFIKASI FIKS
   - Berdasarkan tabel literatur (seperti Sinaga (2025), Rismanto (2020), dan Balek (2024)) serta fakta bahwa teks judul kami rata-rata hanya 16 kata, tetapkan 1 PIPELINE NLP & MODEL FIKS (mulai dari normalisasi entitas nama dosen, tahapan preprocessing bahasa Indonesia, ekstraksi fitur TF-IDF n-gram vs embedding, hingga algoritma utama yang dipilih).
   - Jelaskan mengapa model ini yang paling fiks dipilih dibanding model deep learning yang kompleks (tinjau dari segi akurasi pada korpus kecil, kecepatan komputasi saat diintegrasikan ke web, dan kemudahan interpretasinya).
2. JAWABAN RQ2: STRATEGI PENANGANAN EXTREME CLASS IMBALANCE FIKS
   - Berdasarkan bukti dari tabel penelitian terdahulu dan survei IEEE/ACM, tetapkan 1 STRATEGI FIKS untuk mengatasi kasus ketimpangan dominasi 145 bimbingan vs 10–30 bimbingan.
   - Berikan alasan ilmiah mengapa kita TIDAK menggunakan oversampling sintetis naif (seperti SMOTE konvensional) pada teks judul pendek, dan buktikan mengapa strategi fiks yang Anda pilih (misalnya: Balanced Class Weighting dipadukan dengan Hybrid Cosine Similarity Thresholding) menjamin model tidak bias ke dosen mayoritas.
3. JAWABAN RQ3: METRIK EVALUASI & STANDAR KELAYAKAN (BENCHMARK) FIKS
   - Tetapkan daftar metrik evaluasi fiks yang wajib dihitung untuk sistem rekomendasi ini (khususnya untuk keluaran berupa Top-3 Dosen Pembimbing).
   - Tentukan 1 NILAI AMBANG BATAS ANGKA RIIL (BENCHMARK MINIMUM) agar model SI-REKTA dinyatakan "LAYAK / BAIK" untuk diterapkan di program studi.
   - Jelaskan argumen mengapa akurasi konvensional (Overall Accuracy) dianggap "BURUK/MENYESATKAN" pada kasus dataset kita, serta mengapa Top-3 Accuracy dan Macro-Averaged F1-Score menjadi tolok ukur utama.
4. JAWABAN RQ4: ARSITEKTUR INTEGRASI SISTEM INFORMASI WEB FIKS
   - Berdasarkan artikel yang berhasil mengintegrasikan sistem pada tabel di atas, tetapkan 1 ARSITEKTUR SISTEM WEB FIKS (frontend framework, backend framework, model serving API, dan database).
   - Gambarkan alur kerja data langkah demi langkah: saat mahasiswa menginputkan draf judul skripsi di antarmuka web -> masuk ke API model -> hingga sistem menyajikan kartu rekomendasi Top-3 dosen lengkap dengan persentase kecocokan dan kata kunci penentunya.

[BATASAN / CONSTRAINTS]

1. Wajib Keputusan Definitif (Fiks): Jangan memberikan alternatif yang mengambang. Tentukan 1 kombinasi metodologi terbaik yang siap langsung dieksekusi menjadi file Jupyter Notebook (.ipynb) dan aplikasi web.
2. Berlandaskan Bukti: Setiap argumen wajib merujuk nama penulis/tahun dari artikel pada tabel PRISMA di atas.
3. Gaya Bahasa: Bahasa Indonesia baku, sistematis, sesuai EYD V, dan bernada ilmiah meyakinkan untuk draf laporan tugas besar.

Tambahan **2 artikel** dan keputusan **metodologis final SI-REKTA**: gunakan **TF-IDF n-gram + Linear SVM berbobot kelas**, evaluasi **Top-3 Accuracy dan Macro-F1**, lalu deploy via **web API**.

Berikut respons ini memecah dua kebutuhan Anda: **penambahan artikel ke-10 dan ke-11**, lalu **keputusan final** untuk pipeline NLP, imbalance, evaluasi, dan integrasi web SI-REKTA.

Artikel Tambahan

No	Referensi Lengkap (APA Style 7th)	Tahun & Indeksasi	Karakteristik & Ukuran Dataset	Metode Preprocessing NLP & Algoritma ML / Similarity	Strategi Penanganan Imbalanced Data	Metrik Evaluasi & Nilai Numerik Riil	Indikator Kinerja	Kesimpulan Utama & Hal yang Dapat Ditiru untuk Proyek Kami	Integrasi Sistem Informasi
10	Sinaga, M. N., & Kurniawan, R. R. (2025). *Hyperparameter Optimization of Naive Bayes for Supervisor Recommendation in Computer Science. TIN: Terapan Informatika Nusantara.* DOI: 10.47065/tin.v6i5.8478.	2025 | Jurnal nasional terakreditasi; indeks Sinta tidak tercantum pada korpus	**794 judul skripsi** dan **25 dosen** pada Departemen Ilmu Komputer UIN Sumatera Utara, periode **2019–2024**, split **80:20** (Sinaga & R., 2025)	**Case folding, tokenization, stopword removal, keyword extraction**; klasifikasi **Naive Bayes** berbasis probabilitas dosen relevan (Sinaga & R., 2025)	Tidak dilaporkan resampling eksplisit; mengandalkan kualitas preprocessing dan pembelajaran dari pasangan historis judul–dosen (Sinaga & R., 2025)	**Accuracy 87,3%**, **Precision 85,9%**, **Recall 86,4%** (Sinaga & R., 2025)	Dinilai baik karena akurasi, precision, dan recall sama-sama tinggi pada teks judul pendek, serta hasil dianggap objektif dan transparan (Sinaga & R., 2025)	Naive Bayes efektif sebagai baseline kuat untuk rekomendasi dosen pembimbing berbasis judul pendek dan cocok untuk sistem akademik yang butuh transparansi (Sinaga & R., 2025)	**Ada**; siste **web-base** dengan input judu pilihan scope, dar keluaran **Top-3 superviso** beserta persentas keyakinan (Sinaga & 2025)
11	Fitri, A., Rodiah, D., & Yunita. (2025). *Research Supervisor Recommendation System Using a Hybrid Filtering Approach.* In *2025 International Conference on Artificial Intelligence and Technological Solutions (ICAITech).* DOI/URL tidak tercantum pada korpus yang tersedia.	2025 | Prosiding internasional bereputasi; kuartil tidak tercantum pada korpus	Dataset supervisor recommendation berbasis **judul dan abstrak mahasiswa** serta pola historis assignment dosen; ukuran dataset tidak muncul pada cuplikan (Fitri et al., 2025)	**Hybrid CBF + CF**; komponen **CBF** memakai **TF-IDF + cosine similarity**, komponen **CF** memakai **user-item matrix**, lalu digabung dengan pembobotan (Fitri et al., 2025)	Tidak membahas class weighting atau resampling; strategi utamanya adalah mengimbangi relevansi topik dengan **pola historis assignment** (Fitri et al., 2025)	Kinerja terbaik pada **wCBF = 0,2** dan **wCF = 0,8**, dengan **Hit@5 = 0,8788**, **F1-score = 0,3030**, dan **AUC = 0,8611** (Fitri et al., 2025)	Dinilai baik karena model hybrid lebih akurat dan lebih seimbang daripada CBF atau CF tunggal, terutama saat memanfaatkan pola histori assignment (Fitri et al., 2025)	Relevansi topik saja belum cukup; memasukkan histori penugasan meningkatkan performa ranking, sehingga SI-REKTA layak memakai sinyal historis sebagai fitur atau reranker (Fitri et al., 2025)	Tidak ada integrasi U yang dijelaskan pada cuplikan; fokus pad model rekomend (Fitri et al. 2025)

RQ1

Keputusan fiks RQ1 adalah: **normalisasi nama dosen → preprocessing bahasa Indonesia → TF-IDF word n-gram (1–2) + char n-gram (3–5) → Linear SVM one-vs-rest dengan class_weight='balanced' → output Top-3 + cosine similarity explanation**.

Untuk korpus judul yang sangat pendek, literatur paling konsisten mendukung fitur leksikal ringan seperti **TF-IDF** dan cosine-based matching karena stabil, efisien, dan cocok untuk short text (Hana & Kurniawan, 2025; Bolshakov, 2025). Pada tugas akhir, TF-IDF juga sudah dipakai langsung untuk klasifikasi topik dan rekomendasi pembimbing oleh Rismanto, Fitri, dan studi BITS 2025 (Aksoy et al., 2025; Fitri et al., 2025; Hana & Kurniawan, 2025).

Normalisasi entitas nama dosen harus diletakkan di awal karena inkonsistensi seperti variasi gelar akan merusak label kelas. Tahap baku yang paling aman adalah lowercasing, penghapusan tanda baca dan gelar, pemetaan alias nama ke satu canonical form, tokenisasi, stopword removal, dan stemming, sebagaimana dipakai pada supervisor recommendation Indonesia dan topic classification tesis (Sinaga & R., 2025; Aprianto, 2026; Syabilla et al., 2025; Bagheri et al., 2025).

Model utama dipilih **Linear SVM**, bukan deep learning kompleks. Alasannya, pada klasifikasi topik tesis dengan data tidak seimbang, **SVM mencapai 92,80% accuracy setelah SMOTE** dan mengungguli Naive Bayes (Bagheri et al., 2025; Sinaga & R., 2025). Pada korpus judul 1.057 item, **TF-IDF n-gram + Nearest Centroid** saja sudah mencapai **92,43% accuracy** dan **Macro-F1 0,875**, yang menunjukkan fitur sederhana memang kuat untuk short text (Hana & Kurniawan, 2025). Sementara itu, studi reviewer assignment juga menunjukkan model frekuensi sederhana seperti **BoW/TF-IDF** dapat mengalahkan Doc2Vec hingga **akurasi 99%**, tetap interpretabel, ringan, dan andal pada dataset kecil serta imbalance (Bolshakov, 2025).

Model deep atau embedding penuh tidak dipilih sebagai model inti karena korpus Anda hanya **625 judul** dengan rerata **16 kata**. Studi transformer memang unggul pada reviewer retrieval skala besar dan teks ilmiah lebih panjang (Tsirka et al., 2026; Bagheri et al., 2025), tetapi untuk sistem web kampus yang perlu cepat, murah, dan mudah diaudit, bukti paling aplikatif justru mendukung model ringan yang transparan (Bolshakov, 2025; Sinaga & R., 2025).

- **Pipeline final**: canonicalisasi nama dosen, cleaning, tokenisasi, stopword removal, stemming, TF-IDF word 1–2 + char 3–5, Linear SVM balanced.
- **Penjelasan hasil**: tampilkan top terms kelas dan nearest titles karena workflow ini sudah terbukti auditable (Hana & Kurniawan, 2025; Sinaga & R., 2025).
- **Model pembanding internal**: Naive Bayes sebagai baseline wajib, karena 87,3% accuracy dan mudah direplikasi (Sinaga & R., 2025).

RQ2

Keputusan fiks RQ2 adalah: **jangan gunakan oversampling sintetis naif**; gunakan **balanced class weighting + stratified split + per-class thresholding + hybrid cosine similarity gate pada Top-3**.

Alasan menolak SMOTE konvensional pada judul pendek kuat. Pada tinjauan luas oversampling, semua metode yang diuji pada dataset dunia nyata menghasilkan sampel minoritas yang sering sebenarnya lebih mirip mayoritas, sehingga dinilai tidak andal untuk aplikasi nyata . Tinjauan lain juga menegaskan tidak ada satu resampling yang konsisten unggul di semua eksperimen . Untuk short text 16 kata, sintesis sampel baru berisiko memperparah noise semantik.

Class imbalance Anda bukan sekadar masalah jumlah, tetapi juga risiko model selalu memilih dosen mayoritas. Karena itu, strategi terbaik adalah memberi **bobot lebih besar pada loss kelas minoritas**, menjaga distribusi asli lewat **stratified sampling**, lalu menahan prediksi berisiko dengan **cosine similarity threshold** terhadap profil dosen. Literatur evaluasi imbalance menekankan bahwa F1 lebih stabil daripada accuracy pada data timpang (Sinaga & R., 2025; Hana & Kurniawan, 2025). Studi reviewer assignment modern juga menunjukkan fairness dan workload harus masuk ke tahap assignment, bukan hanya tahap similarity (Bagheri et al., 2026; Aksoy et al., 2025; Aprianto, 2026).

Hybrid thresholding dipilih karena reviewer matching berbasis ranking menunjukkan bahwa **Top-k performance** dan **load balance** harus dipantau bersama (Bagheri et al., 2026; Bagheri et al., 2025). Secara operasional, jika probabilitas kelas tinggi tetapi cosine terhadap profil publikasi dosen rendah, rekomendasi itu diturunkan peringkatnya. Mekanisme ini mengurangi bias ke dosen dominan yang sering muncul akibat prior label.

- **Tidak memakai SMOTE naif** pada judul pendek karena sintetisnya tidak reliabel pada domain imbalance nyata .
- **Memakai bobot kelas seimbang** agar kesalahan pada dosen minoritas dihukum lebih besar.
- **Memakai cosine gate** agar dosen mayoritas tidak naik hanya karena frekuensi historis, tetapi juga harus lolos relevansi topik.

RQ3

Keputusan fiks RQ3 adalah: metrik wajib SI-REKTA ialah **Top-1 Accuracy, Top-3 Accuracy, Macro-F1, Weighted-F1, Macro-Recall, MRR, Precision@3, Recall@3, confusion matrix, dan Gini beban rekomendasi**. **Benchmark minimum kelayakan** ditetapkan: **Top-3 Accuracy ≥ 0,80**, **Macro-F1 ≥ 0,70**, dan **MRR ≥ 0,60**.

Accuracy tunggal menyesatkan pada dataset Anda karena satu dosen memiliki **145** bimbingan, sehingga model yang sering menebak dosen mayoritas bisa tampak tinggi walau gagal pada dosen minoritas. Literatur imbalance menunjukkan accuracy dan precision saja tidak robust pada distribusi timpang, sedangkan **F1** paling seimbang (Sinaga & R., 2025; Hana & Kurniawan, 2025; Aksoy et al., 2025). Karena keluaran SI-REKTA berupa **Top-3 dosen**, metrik ranking harus wajib dipakai. Studi reviewer assignment modern memakai **MRR@3, Precision@3, MAP@3**, dan menilai konsentrasi top-3 secara langsung (Bagheri et al., 2026; Bagheri et al., 2025). Studi hybrid supervisor recommendation juga melaporkan **Hit@5, F1, dan AUC**, sedangkan studi TF-IDF+SBERT memakai **Acc@3, Acc@5, dan MRR** (Fitri et al., 2025; Sajid et al., 2026).

Ambang minimum dipilih dari studi sejenis. Sistem supervisor web berbasis Naive Bayes mencapai **87,3% accuracy**, **85,9% precision**, **86,4% recall** (Sinaga & R., 2025). Sistem supervisor hybrid TF-IDF+SBERT mencapai **Acc@3 0,8056** dan **MRR 0,6607** (Sajid et al., 2026). Klasifikasi topik tugas akhir berbasis TF-IDF n-gram mencapai **Macro-F1 0,875** (Hana & Kurniawan, 2025). Karena dataset SI-REKTA lebih timpang daripada sebagian studi itu, standar yang defensibel tetapi realistis ialah **Top-3 Accuracy 0,80**, **Macro-F1 0,70**, dan **MRR 0,60**.

- **Layak/Baik** jika ketiga ambang minimal tercapai bersamaan.
- **Buruk** jika accuracy tinggi tetapi Macro-F1 rendah, karena itu tanda model menekan kelas minoritas.
- **Wajib tambah metrik fairness** distribusi rekomendasi, misalnya Gini, karena workload realism sudah dipakai pada reviewer assignment mutakhir (Bagheri et al., 2026).

RQ4

Keputusan fiks RQ4 adalah: **frontend React**, **backend FastAPI**, **model service Python scikit-learn**, dan **PostgreSQL** sebagai database utama.

Literatur yang paling dekat dengan kebutuhan implementasi kampus menunjukkan bahwa sistem supervisor recommendation perlu **web-based**, memberi input judul, dan mengembalikan **Top-3 supervisor dengan confidence** (Sinaga & R., 2025). Studi lain menunjukkan backend **Flask + RESTful API + chatbot** sudah cukup untuk sistem rekomendasi pendidikan (Hana & Kurniawan, 2025), dan workflow kurasi judul berbasis **Streamlit web app** juga terbukti untuk training, prediction, dan retrieval judul serupa (Hana & Kurniawan, 2025). Karena SI-REKTA membutuhkan pemisahan jelas antara UI dan model, FastAPI lebih cocok sebagai API serving yang ringan dan native untuk Python ML.

Alur kerja finalnya sebagai berikut. Mahasiswa mengetik judul di frontend. Backend mengirim teks ke endpoint `` `/predict` ``. Service model melakukan normalisasi teks dan canonicalisasi nama dosen, lalu memanggil vectorizer TF-IDF dan model Linear SVM. Setelah probabilitas semua dosen dihitung, modul reranking memeriksa cosine similarity ke profil dosen dan aturan fairness sederhana agar tidak selalu menumpuk pada dosen mayoritas. Sistem lalu mengembalikan **Top-3 dosen**, **persentase kecocokan**, dan **kata kunci penentu** dari bobot TF-IDF/top terms kelas. Hasil ini ditampilkan sebagai tiga kartu rekomendasi dan sekaligus disimpan ke PostgreSQL untuk audit, retraining, dan evaluasi beban (Sinaga & R., 2025; Hana & Kurniawan, 2025; Bolshakov, 2025).

- **Frontend**: React form input judul, hasil Top-3, riwayat rekomendasi.
- **Backend/API**: FastAPI dengan endpoint `` `train` ``, `` `predict` ``, `` `evaluate` ``, `` `feedback` ``.
- **Database**: PostgreSQL untuk data dosen, judul historis, log rekomendasi, dan kamus alias nama dosen.

Keputusan final untuk SI-REKTA adalah **TF-IDF n-gram + Linear SVM berbobot kelas + cosine reranking + evaluasi Top-3 + deploy web API**, karena kombinasi ini paling sesuai dengan **judul sangat pendek**, **kelas sangat timpang**, **kebutuhan interpretabilitas**, dan **integrasi web kampus** (Hana & Kurniawan, 2025; Sinaga & R., 2025; Bolshakov, 2025; Sajid et al., 2026; Aksoy et al., 2025).

These search results were found and analyzed using Consensus, an AI-powered search engine for research. Try it at https://consensus.app. © 2026 Consensus NLP, Inc. Personal, non-commercial use only; redistribution requires copyright holders' consent.

References

Aksoy, M., Ugurlu, S., & Amasyalı, M. (2025). A data-driven optimization approach for automated reviewer assignment using natural language processing. *Intell. Syst. Appl., 28*, 200587. https://doi.org/10.1016/j.iswa.2025.200587

Aprianto, H. (2026). Pendekatan Model TF-IDF dan Cosine Similarity Pada Rekomendasi Dosen Pembimbing Skripsi. *BETRIK*. https://doi.org/10.36050/bzdpf251

Bagheri, F., Buscaldi, D., & Recupero, R. D. (2025). Leveraging knowledge graphs and LLMs for content-based reviewer assignment. *Journal of Intelligent Information Systems, 64*, 349 - 377. https://doi.org/10.1007/s10844-025-01004-9

Bagheri, F., Buscaldi, D., & Recupero, D. (2026). LLM-Assisted Reviewer Assignment via Auditable Expertise Matching. *IEEE Access, 14*, 127834-127863. https://doi.org/10.1109/access.2026.3724622

Bolshakov, D. (2025). A reviewer identification using machine learning methods. *Science Editor and Publisher*. https://doi.org/10.24069/sep-25-35

Fitri, A., Rodiah, D., & Y. (2025). Research Supervisor Recommendation System Using a Hybrid Filtering Approach. *2025 International Conference on Artificial Intelligence and Technological Solutions (ICAITech)*, 342-345. https://doi.org/10.1109/icaitech66481.2025.11387283

Hana, R. C., & Kurniawan, D. (2025). Implemetasi TF-IDF N-Gram dan Algoritma Nearest Centroid untuk Klasifikasi Topik Tugas Akhir. *Building of Informatics, Technology and Science (BITS)*. https://doi.org/10.47065/bits.v7i3.8859

Sajid, S., Fadil, N., Mtd, A. H., & Ajiwinata, H. G. (2026). Hybrid TF-IDF and Sentence-BERT for Academic Advisor Recommendation Enhancing Topic Matching in Undergraduate Theses. *Jurnal Edukasi dan Penelitian Informatika (JEPIN)*. https://doi.org/10.26418/jp.v12i2.106621

Sinaga, M. N., & R., K. R. (2025). Hyperparameter Optimization of Naive Bayes for Supervisor Recommendation in Computer Science. *TIN: Terapan Informatika Nusantara*. https://doi.org/10.47065/tin.v6i5.8478

Syabilla, M., Zeniarja, J., & Nabila, Q. (2025). Implementasi LDA, TF-IDF, dan BERT dalam Sistem Rekomendasi Dosen Pembimbing untuk Mahasiswa. *Building of Informatics, Technology and Science (BITS)*. https://doi.org/10.47065/bits.v6i4.6499

Tsirka, C., Stergiopoulos, V., Tousidou, E., Vassilakopoulos, M., & Corral, A. (2026). Semantic Retrieval for the Reviewer Assignment Problem: An Evaluation of Transformer-Based Language Models. 1256-1263. https://doi.org/10.5220/0015047900004018